

PROJETO FINAL

Desenvolvimento de Camada Convolutacional 2D

Quatro variantes de Conv2D aplicadas à classificação multiclasse de imagens
dermatoscópicas no dataset Skin Cancer MNIST HAM10000

Osevaldo da Silva Farias

Introdução ao Deep Learning, UFMA, PPGCC, 2026.1

Professor Dr. João Dallyson Sousa de Almeida

São Luís (MA), 6 de julho de 2026

Roteiro da apresentação

01 Contexto e objetivo do experimento

02 As quatro variantes de convolução 2D

03 Arquitetura da CNN experimental

04 Comparação dos filtros aprendidos

05 Mapas de ativação e Grad-CAM

06 Convergência e matrizes de confusão

07 Métricas e resultados quantitativos

08 Balanceamento de classes e conclusão

Objetivo do experimento

Investigar como diferentes implementações de camada convolucional 2D influenciam o aprendizado de uma CNN

O dataset utilizado é o Skin Cancer MNIST, HAM10000, composto por imagens de lesões de pele rotuladas em sete classes. A arquitetura da rede é idêntica nos quatro experimentos, sendo o tipo de convolução o único fator de alteração composicional.

Sete classes diagnósticas

- Ceratose actínica, akiec, 327 amostras
- Carcinoma basocelular, bcc, 514 amostras
- Lesão benigna, bkl, 1099 amostras
- Dermatofibroma, df, 115 amostras
- Melanoma, mel, 1113 amostras
- Nevo melanocítico, nv, 6705 amostras
- Lesão vascular, vasc, 142 amostras

7.010 imagens de treino

1.502 imagens de validação

1.503 imagens de teste

224 x 224 resolução de entrada

Ponto de partida para o experimento

K é o tamanho do kernel, Cin e Cout são os canais de entrada e de saída, o termo +Cout é o viés de cada filtro

● CNN A, Tradicional

$$\text{Params} = (K \times K \times \text{Cin} \times \text{Cout}) + \text{Cout}$$

Fórmula padrão de uma convolução 2D, contando pesos e viés de cada filtro de saída.

● CNN B, Dilatada

$$\text{Params} = (K \times K \times \text{Cin} \times \text{Cout}) + \text{Cout}$$

Mesma fórmula da tradicional. A dilatação insere espaços entre os pesos do kernel, mas não cria pesos novos.

● CNN C, Depthwise separável

$$\text{Params} = (K \times K \times \text{Cin}) + (\text{Cin} \times \text{Cout})$$

Soma da etapa depthwise, $K \times K \times \text{Cin}$, com a etapa pointwise, $1 \times 1 \times \text{Cin} \times \text{Cout}$, que funde os canais.

● CNN D, Kernel 5 x 5

$$\text{Params} = (25 \times \text{Cin} \times \text{Cout}) + \text{Cout}$$

Mesma fórmula da tradicional, substituindo K por 5, já que 5×5 é igual a 25.

Comparando uma convolução tradicional 3 x 3 com uma depthwise separável de mesmo kernel, a redução é de aproximadamente 1 sobre $K \times K$, cerca de 1 nono do total original para kernels 3 x 3, conforme Li et al, 2025.

As quatro variantes de convolução 2D

Primeira camada da rede, 3 canais de entrada, 32 filtros

Variante	Parâmetros	Campo receptivo	Contexto
● CNN A, Tradicional	896	3 x 3	Local, baseline
● CNN B, Dilatada	896	7 x 7	Mais amplo, por dilatação
● CNN C, Depthwise separável	155	3 x 3	Local, baixo custo
● CNN D, Kernel 5 x 5	2.432	5 x 5	Mais amplo, por kernel maior

A convolução dilatada amplia o campo receptivo sem custo adicional de parâmetros. A depthwise separável utiliza aproximadamente 17% do número de parâmetros das variantes CNN A e CNN B

Arquitetura da CNN experimental

O único elemento que varia entre os quatro experimentos é o tipo de camada convolucional



Entrada, imagem RGB 224 x 224. Os filtros crescem em 32, 64, 128 e 256 unidades ao longo das camadas. O tipo de convolução, tradicional, dilatada, depthwise ou kernel 5x5, é aplicado igualmente nos quatro blocos convolucionais.


Total de parâmetros treináveis por variante

CNN A	CNN B	CNN C	CNN D
524.551	524.551	181.762	1.214.215

Comparação dos filtros

Pesos da primeira camada convolucional


CNN A, Tradicional




CNN B, Dilatada



CNN C, Depthwise separável



CNN D, Kernel 5 x 5




CNN A e B tem filtros coloridos, pois operam sobre os 3 canais RGB. A CNN C aparece em tons de cinza, filtro isolado por canal. A CNN D usa kernel 5 x 5, maior que o das demais.

Comparação dos mapas de ativação

Camadas 1 e 2, após convolução seguida de ReLU

CNN A, Tradicional




- Características em diferentes níveis, sobre a mesma imagem de teste. A convolução dilatada tende a ativar regiões mais amplas, pelo campo receptivo maior.

Comparação dos mapas de ativação

Camadas 1 e 2, após convolução seguida de ReLU

CNN B, Dilatada




- Características em diferentes níveis, sobre a mesma imagem de teste. A convolução dilatada tende a ativar regiões mais amplas, pelo campo receptivo maior.

Comparação dos mapas de ativação

Camadas 1 e 2, após convolução seguida de ReLU

CNN C, Depthwise separável




- *Características em diferentes níveis, sobre a mesma imagem de teste. A convolução dilatada tende a ativar regiões mais amplas, pelo campo receptivo maior.*

Comparação dos mapas de ativação

Camadas 1 e 2, após convolução seguida de ReLU

CNN D, Kernel 5 x 5




- Características em diferentes níveis, sobre a mesma imagem de teste. A convolução dilatada tende a ativar regiões mais amplas, pelo campo receptivo maior.

Grad-CAM, regiões que mais influenciaram a decisão

Gradiente da classe prevista em relação aos mapas de ativação da segunda camada, imagem real de teste

CNN A, Tradicional




- *Mapa quase uniforme, com pouco sinal de gradiente sobre a lesão, indício de saturação nesta camada.*

Grad-CAM, regiões que mais influenciaram a decisão

Gradiente da classe prevista em relação aos mapas de ativação da segunda camada, imagem real de teste

CNN B, Dilatada




- *Ativações dispersas em vários pontos, nem sempre alinhadas ao contorno da lesão.*

Grad-CAM, regiões que mais influenciaram a decisão


Gradiente da classe prevista em relação aos mapas de ativação da segunda camada, imagem real de teste

CNN C, Depthwise separável


Imagem original



Mapa Grad-CAM



Sobreposição




- Cobertura mais ampla e concentrada sobre toda a área da lesão, mapa aparentemente mais coerente clinicamente.

Grad-CAM, regiões que mais influenciaram a decisão

Gradiente da classe prevista em relação aos mapas de ativação da segunda camada, imagem real de teste


CNN D, Kernel 5 x 5



● *Pontos de ativação esparsos e isolados, pouco alinhados com a lesão.*


Convergência do treinamento

Perda por época (média móvel de 5 épocas)



A partir da época 25, a perda de treino segue caindo enquanto a validação estabiliza, sinal de leve overfitting nas quatro variantes. **A CNN B, dilatada,** mantém a menor perda de treino no processo todo.

Convergência do treinamento




A partir da época 25, a perda de treino segue caindo enquanto a validação estabiliza, sinal de leve overfitting nas quatro variantes. **A CNN B, dilatada,** mantém a menor perda de treino no processo todo.

Matrizes de confusão no conjunto de teste


Sete classes, 1.503 imagens de teste, contagem absoluta de previsões

CNN A, Tradicional



Em todas as variantes, boa parte dos erros ocorre entre mel, bkl e nv, classes visualmente semelhantes. A CNN C teve a melhor discriminação de bkl, com 89 acertos. A classe df, mais rara, segue a mais difícil em todas.


CNN B, Dilatada



Matrizes de confusão no conjunto de teste


Sete classes, 1.503 imagens de teste, contagem absoluta de previsões

CNN C, Depthwise separável



Em todas as variantes, boa parte dos erros ocorre entre mel, bkl e nv, classes visualmente semelhantes. A CNN C teve a melhor discriminação de bkl, com 89 acertos. A classe df, mais rara, segue a mais difícil em todas.

CNN D, Kernel 5 x 5



Métricas de avaliação mais aceitas

Média macro sobre as sete classes do conjunto de teste

Acurácia

Proporção geral de acertos. Pode ser enganosa em datasets desbalanceados como o HAM10000.

Precisão

Entre as previsões de uma classe, quantas estavam corretas, com média macro entre as sete classes.

Recall

Entre os casos reais de uma classe, quantos foram identificados corretamente.

F1-score macro


Média harmônica entre precisão e recall, adotada como métrica principal por ser mais sensível às classes minoritárias.

A análise qualitativa é conduzida por três recursos complementares, mapas de ativação, filtros aprendidos e Grad-CAM.

Resultados quantitativos no conjunto de teste


Métricas com média macro sobre as sete classes, 1.503 imagens

Variante	Acurácia	Precisão	Recall
● CNN A, Tradicional	0,6108	0,5100	0,6381
● CNN B, Dilatada	0,6707	0,5201	0,6597
● CNN C, Depthwise	0,6647	0,5119	0,6381
● CNN D, Kernel 5x5	0,6161	0,4701	0,6112



A CNN B, dilatada, obteve o melhor desempenho em todas as métricas. A CNN C, depthwise, ficou em segundo lugar com 82,7% menos parâmetros na primeira camada. A CNN D, kernel 5x5, ficou abaixo da tradicional, com custo paramétrico 171% maior.

Validação cruzada, dilatada contra depthwise



Validação cruzada, dilatada contra depthwise

5 folds estratificados, comparação pareada fold a fold, mesmo conjunto de teste

Variante	Acurácia		Precisão		Recall		F1-score	
	Média	Desvio	Média	Desvio	Média	Desvio	Média	Desvio
CNN B, Dilatada	0,619	0,026	0,485	0,024	0,616	0,031	0,507	0,030
CNN C, Depthwise	0,635	0,017	0,491	0,032	0,652	0,020	0,525	0,027

Nenhuma diferença estatisticamente significativa

Média e desvio padrão entre os 5 folds

A diferença entre as médias das duas variantes é menor do que a variação que cada uma já tem sozinha de um fold para o outro.

A depthwise venceu em quatro dos 5 folds por uma margem parecida com as vitórias dela nos outros folds.

Com apenas 5 folds, essa comparação ainda é incerta demais para indicar uma variante vencedora. A leitura mais evidente é que essas duas têm desempenho equivalente, dentro da margem de incerteza dos dados.

Efeito do balanceamento de classes

WeightedRandomSampler aplicado ao conjunto de treino

O HAM10000 é um dataset desbalanceado, a classe nv concentra a maior parte das amostras. Um WeightedRandomSampler foi usado para equilibrar a distribuição dos batches durante o treinamento, dando peso maior às amostras de classes minoritárias, como df e vasc.

O tratamento do desbalanceamento é uma decisão de projeto tão relevante quanto a escolha da variante convolucional.

+ 14% F1-score macro

+ 27% recall

Comparação em relação a um experimento preliminar conduzido sem estratégia de balanceamento de classes.

CONCLUSÃO

O que o comparativo mostrou

01

Dilated e depthwise, desempenho equivalente

Validação cruzada de 5 folds não encontrou diferença estatisticamente significativa entre as duas em nenhuma das quatro métricas.

02

Depthwise é a escolha mais vantajosa

Com desempenho estatisticamente equivalente, a redução de 82,7% nos parâmetros favorece a depthwise entre as duas.

03

Kernel maior não garantiu ganho

A CNN D ficou abaixo da tradicional em F1-score, com 171% mais parâmetros na primeira camada.

04

Explicabilidade também favoreceu a depthwise

O Grad-CAM da CNN C apresentou maior cobertura da região central da lesão, mais coerente clinicamente.

Referências bibliográficas

- TSCHANDL, P. et al. The HAM10000 dataset. Scientific Data, 2018.
- CHOLLET, F. Xception, deep learning with depthwise separable convolutions. CVPR, 2017.
- DUTRA, E. F. P.; LEMOS, V. H. B.; ALMEIDA, J. D. S.; PAIVA, A. C. Método automático para geração de laudos médicos em imagens de retinografia utilizando Transformer. Anais do..., 2024
- SIMONYAN, K., ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. ICLR, 2015.
- MATOS, C. E. F.; BRAZ JUNIOR, G.; ALMEIDA, J. D. S.; PAIVA, A. C. CPP-UNet: Combined Pyramid Pooling Modules in the U-Net Network for Kidney, Tumor and Cyst Segmentation. IEEE Latin America Transactions, v. 22, n. 8, p. 642-650, ago. 2024.
- MUSTHAFA, M. M. et al. Enhanced skin cancer diagnosis using optimized CNN architecture. BMC Medical Imaging, 2024.
- LAN, L. et al. MSLAU-Net, a hybrid CNN-Transformer network for medical image segmentation. arXiv, 2025.
- SELVARAJU, R. R. et al. Grad-CAM, visual explanations from deep networks via gradient-based localization. ICCV, 2017.

PROJETO FINAL

Desenvolvimento de Camada Convolutacional 2D

Obrigado!

Osevaldo da Silva Farias

Introdução ao Deep Learning, UFMA, PPGCC, 2026.