

Desenvolvimento de Camada Convolutacional 2D aplicado à classificação de imagens dermatoscópicas

Experimentos no domínio do Dataset Derma MNIST HAM10000

Osevaldo da Silva Farias

¹Universidade Federal do Maranhão (UFMA)

Avenida dos Portugueses, Campus do Bacanga - São Luís - MA - Brazil

osevaldo.farias@discente.ufma.br

Abstract. *This work investigates how different implementations of the 2D convolutional layer affect the learning of Convolutional Neural Networks applied to dermatoscopic image classification. Four variants are compared under identical conditions on the HAM10000 dataset (10,015 images, seven classes): traditional 3x3, dilated (dilation=2), depthwise separable, and 5x5 kernel. Only the convolutional layer type varies across experiments, and class imbalance is handled with a WeightedRandomSampler. The dilated convolution achieved the best single-run performance (67.07% accuracy, 55.82% macro F1-score), while the 5x5 kernel fell below the traditional baseline in F1-score, showing that a larger receptive field via kernel size does not guarantee better results. A 5-fold cross-validation between the two best variants indicated equivalent performance. Qualitative analysis through activation maps, filter visualization, and Grad-CAM corroborates the quantitative findings.*

Resumo. *Este trabalho investiga como diferentes implementações da camada convolutacional 2D afetam o aprendizado de Redes Neurais Convolucionais aplicadas à classificação de imagens dermatoscópicas. Quatro variantes são comparadas sob condições idênticas no dataset HAM10000 (10.015 imagens, sete classes): tradicional 3x3, dilatada (dilation=2), depthwise separável e kernel 5x5. Apenas o tipo de camada convolutacional varia entre os experimentos, e o desbalanceamento de classes é tratado com um WeightedRandomSampler. A convolução dilatada obteve o melhor desempenho em execução única (acurácia de 67,07% e F1-score macro de 55,82%), enquanto o kernel 5x5 ficou abaixo da tradicional em F1-score, mostrando que um campo receptivo maior pelo tamanho do kernel não garante melhor resultado. Uma validação cruzada de 5 folds entre as duas melhores variantes indicou desempenho equivalente. A análise qualitativa por mapas de ativação, visualização de filtros e Grad-CAM corrobora os resultados quantitativos.*

1. Introdução

A classificação automática de imagens médicas é uma das aplicações mais promissoras do aprendizado profundo na área da saúde. Em dermatologia, a identificação precoce de

lesões malignas como o melanoma pode determinar diretamente o prognóstico do paciente, tornando sistemas de auxílio ao diagnóstico uma ferramenta de grande relevância clínica [Tschandl et al. 2018].

Redes Neurais Convolucionais (CNNs) têm demonstrado desempenho competitivo nessa tarefa, com resultados comparáveis aos de dermatologistas experientes em benchmarks públicos [Esteva et al. 2017]. O componente central dessas arquiteturas é a camada convolucional 2D (Conv2D), responsável pela extração hierárquica de características visuais a partir das imagens de entrada. Diferentes implementações dessa camada produzem comportamentos distintos em termos de campo receptivo, número de parâmetros e padrões aprendidos, influenciando diretamente a capacidade discriminativa do modelo.

Apesar da relevância do projeto da camada convolucional, poucos trabalhos investigam de forma comparativa e controlada o impacto de diferentes variantes dessa camada sobre o mesmo dataset e a mesma arquitetura base. A maioria dos estudos avalia arquiteturas completas pré-treinadas, dificultando a atribuição dos resultados a componentes específicos da rede.

Este trabalho investiga como quatro implementações distintas da camada Conv2D afetam o desempenho, o aprendizado dos filtros e a atenção visual de CNNs aplicadas à classificação de imagens dermatoscópicas. As variantes avaliadas são a convolução tradicional com kernel 3×3 , utilizada como baseline, a convolução dilatada com $\text{dilation}=2$, a convolução depthwise separável e a convolução com kernel 5×5 . Os experimentos utilizam o dataset HAM10000 [Tschandl et al. 2018], composto por 10.015 imagens de lesões de pele distribuídas em sete classes, com arquitetura idêntica entre os quatro modelos e variação exclusiva do tipo de camada convolucional.

As principais contribuições deste trabalho são: (i) a implementação e comparação controlada de quatro variantes convolucionais sob as mesmas condições experimentais; (ii) a análise do impacto do balanceamento de classes sobre as métricas de avaliação em datasets dermatoscópicos desbalanceados; e (iii) a investigação qualitativa do aprendizado por meio de mapas de ativação, visualização de filtros e Grad-CAM comparativo entre as quatro variantes.

O restante do artigo está organizado da seguinte forma. A Seção 2 apresenta uma breve revisão da literatura sobre CNNs e variantes convolucionais. A Seção 3 descreve a metodologia experimental. A Seção 4 apresenta e discute os resultados. A Seção 5 conclui o trabalho e aponta direções futuras.

2. Revisão da Literatura

A classificação automática de lesões de pele por meio de redes neurais convolucionais tem recebido atenção crescente na literatura recente. Khan et al. [Khan et al. 2026] demonstraram que arquiteturas baseadas em EfficientNetB4 com mecanismos de atenção atingem acurácia de 93,09% e F1-score macro de 0,8352 no dataset HAM10000, evidenciando o potencial de CNNs profundas para o diagnóstico dermatoscópico assistido. Os autores destacam que o desbalanceamento severo entre classes, com o nevo melanocítico representando cerca de 67% das amostras, impõe desafios específicos ao treinamento e deve ser tratado explicitamente durante o processo de otimização.

No contexto de arquiteturas leves e eficientes, Li et al. [Li et al. 2025] propuseram uma variante de U-Net com convoluções depthwise separáveis para segmentação de lesões de pele, demonstrando que a separação da operação convolucional em etapas depthwise e pointwise reduz significativamente o número de parâmetros sem comprometer a capacidade representacional do modelo. A convolução depthwise separável, introduzida por Chollet [Chollet 2017] como componente central da arquitetura Xception, aplica um filtro independente por canal de entrada na etapa depthwise e combina as informações entre canais com uma convolução 1×1 na etapa pointwise, resultando em uma diminuição de parâmetros proporcional ao número de canais de entrada.

A convolução dilatada tem se consolidado como recurso relevante para ampliar o campo receptivo efetivo sem aumentar o custo paramétrico da camada. Chen et al. [Chen et al. 2025] e Lan et al. [Lan et al. 2023] demonstram que convoluções dilatadas permitem capturar dependências espaciais de longo alcance em imagens médicas, superando a limitação do campo receptivo fixo das convoluções tradicionais. O campo receptivo efetivo de uma camada convolucional dilatada com kernel de tamanho k e taxa de dilatação d é dado por $k + d \times (k - 1)$, resultando em 7×7 para $k = 3$ e $d = 2$, sem adição de parâmetros em relação à convolução tradicional de mesmo tamanho de kernel [Lan et al. 2023].

O impacto do desbalanceamento de classes sobre as métricas de avaliação é amplamente documentado na literatura. Appasami e Savarimuthu [Appasami and Savarimuthu 2024] demonstraram que a acurácia geral pode ser enganosa em datasets dermatoscópicos desbalanceados, onde modelos com alta acurácia frequentemente ignoram as classes minoritárias clinicamente mais relevantes, como melanoma e carcinoma basocelular. Os autores recomendam o uso de métricas macro como F1-score e recall por classe para uma avaliação mais fiel da capacidade discriminativa do modelo.

Métodos de balanceamento como o WeightedRandomSampler e a ponderação de classes na função de perda têm sido amplamente adotados para mitigar esse problema. Almeida et al. [Almeida et al. 2025] e Khan et al. [Khan et al. 2026] relatam ganhos expressivos em F1-score macro ao incorporar estratégias de balanceamento durante o treinamento no HAM10000, confirmando que essa decisão de projeto impacta diretamente o desempenho nas classes minoritárias.

Diferentemente dos trabalhos citados, que avaliam arquiteturas completas ou propõem novas variantes de forma isolada, este trabalho adota uma abordagem comparativa controlada. A arquitetura base permanece idêntica nos quatro experimentos, variando exclusivamente o tipo de camada convolucional entre tradicional com kernel 3×3 , dilatada com $\text{dilation}=2$, depthwise separável e kernel 5×5 . Esta metodologia permite atribuir diretamente ao tipo de convolução as diferenças observadas no desempenho, nos padrões aprendidos e na atenção visual do modelo.

3. Metodologia

3.1. Dataset

Os experimentos utilizam o dataset HAM10000 (*Human Against Machine with 10000 training images*), apresentado por Tschandl et al. [Tschandl et al. 2018]. O dataset é

composto por 10.015 imagens dermatoscópicas coloridas no formato RGB, com resolução original de 600×450 pixels, distribuídas em sete classes: ceratose actínica (akiec), carcinoma basocelular (bcc), lesão benigna semelhante à ceratose (bkl), dermatofibroma (df), melanoma (mel), nevo melanocítico (nv) e lesão vascular (vasc). O dataset apresenta forte desbalanceamento entre classes, com a classe nv representando aproximadamente 67% das amostras (6.705 imagens), enquanto as classes df e vasc contam com apenas 115 e 142 imagens, respectivamente.

O dataset foi dividido em três subconjuntos de forma estratificada por classe: 70% para treinamento (7.010 imagens), 15% para validação (1.502 imagens) e 15% para teste (1.503 imagens). A estratificação garante que a distribuição original das classes seja preservada em cada subconjunto.

3.2. Pré-processamento e aumento de dados

Todas as imagens foram redimensionadas para 224×224 pixels antes de serem fornecidas à rede. A normalização foi aplicada com média (0,763, 0,546, 0,570) e desvio padrão (0,141, 0,152, 0,169) por canal, calculados sobre o conjunto de treinamento do HAM10000.

As imagens de treinamento receberam as seguintes transformações de aumento de dados: espelhamento horizontal e vertical aleatório, rotação aleatória de até 20 graus e variação aleatória de brilho, contraste e saturação (*color jitter*). As imagens de validação e teste receberam apenas redimensionamento e normalização, garantindo uma avaliação limpa do desempenho dos modelos.

Para mitigar o desbalanceamento entre classes, foi adotado o *WeightedRandomSampler* do PyTorch durante o treinamento. Cada amostra recebe um peso inversamente proporcional à frequência de sua classe, de forma que o modelo observe uma distribuição mais equilibrada entre as sete classes a cada *batch* de treinamento [Khan et al. 2026].

3.3. Variantes convolucionais

Quatro variantes de camada convolucional 2D foram implementadas como módulos `nn.Module` independentes no PyTorch. A operação fundamental da convolução 2D é definida por:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (1)$$

onde I é a imagem de entrada, K é o kernel de convolução e S é o mapa de ativação resultante. O número de parâmetros de uma camada convolucional com kernel $k \times k$, C canais de entrada e F filtros de saída é dado por $k \times k \times C \times F + F$.

Conv2D Tradicional (CNN A): aplica F filtros de tamanho $k \times k$ sobre todos os C canais de entrada simultaneamente. Utilizada como baseline do experimento, com kernel 3×3, produzindo 896 parâmetros na primeira camada. O campo receptivo efetivo é de 3×3 pixels.

Conv2D Dilatada (CNN B): insere espaços entre os elementos do kernel controlados pelo parâmetro *dilation*. O campo receptivo efetivo é calculado por $k + d \times (k - 1)$,

resultando em 7×7 pixels para $k = 3$ e $d = 2$, sem adição de parâmetros em relação à variante tradicional [Lan et al. 2023].

Depthwise Separável (CNN C): decompõe a convolução em duas etapas sequenciais. A etapa *depthwise* aplica um filtro independente por canal de entrada, e a etapa *pointwise* combina os canais com uma convolução 1×1 [Chollet 2017, Li et al. 2025]. Esta separação reduz o número de parâmetros da primeira camada de 896 para 155, uma diminuição de 82,7%.

Conv2D com Kernel 5×5 (CNN D): utiliza a mesma operação da convolução tradicional com kernel de tamanho 5×5 , ampliando o campo receptivo para 5×5 pixels sem o recurso de espaçamento da variante dilatada. O número de parâmetros na primeira camada aumenta para 2.432, um acréscimo de 171% em relação à tradicional.

A Tabela 1 resume as características das quatro variantes considerando a primeira camada convolucional do experimento.

Tabela 1. Comparação das quatro variantes convolucionais (1ª camada: 3 canais de entrada, 32 filtros).

Variante	Parâmetros	Campo rec.	Contexto
Tradicional (CNN A)	896	3×3	Local
Dilatada (CNN B)	896	7×7	Mais amplo (Dilatação)
Depthwise (CNN C)	155	3×3	Local
Kernel 5×5 (CNN D)	2.432	5×5	Mais amplo (Kernel maior)

3.4. Arquitetura da CNN experimental

A CNN experimental possui quatro camadas convolucionais com filtros crescentes de 32, 64, 128 e 256, seguidas de Batch Normalization e ativação ReLU após cada camada. As duas primeiras camadas convolucionais são seguidas de MaxPool 2×2 . Após a quarta camada, um *AdaptiveAvgPool2d* reduz o mapa de ativação para 1×1 , evitando o custo paramétrico excessivo de uma camada *Flatten* direto sobre a resolução 224×224 . As camadas lineares consistem em uma camada totalmente conectada de 512 neurônios com Dropout de 0,5 e uma camada de saída com 7 neurônios correspondentes às sete classes do HAM10000.

O único elemento que varia entre os quatro experimentos é o tipo de camada convolucional. Todos os demais componentes da arquitetura, incluindo Batch Normalization, pooling, camadas lineares e hiperparâmetros, permanecem idênticos, garantindo que qualquer diferença observada nos resultados seja atribuída exclusivamente ao tipo de convolução utilizada.

Considerando a arquitetura completa, o total de parâmetros treináveis é de 524.551 para a CNN A tradicional, 524.551 para a CNN B dilatada, 181.762 para a CNN C depthwise separável e 1.214.215 para a CNN D com kernel 5×5 , confirmando a economia paramétrica da variante depthwise também no nível da rede inteira.

3.5. Configuração do treinamento

Os quatro modelos foram treinados com os seguintes hiperparâmetros: otimizador Adam com *learning rate* inicial de 10^{-3} e *weight decay* de 10^{-4} , função de perda *CrossEntropy-Loss*, *batch size* de 32 e 50 épocas de treinamento [Appasami and Savarimuthu 2024].

O *scheduler* ReduceLROnPlateau foi configurado com fator de diminuição de 0,5 e paciência de 5 épocas, reduzindo o *learning rate* automaticamente quando a perda de validação deixava de melhorar. Todos os experimentos foram executados em GPU Kaggle T4 e os resultados foram registrados no Weights & Biases.

3.6. Métricas de avaliação

O desempenho dos modelos foi avaliado sobre o conjunto de teste com as seguintes métricas calculadas com média macro sobre as sete classes: acurácia global, precisão, recall e F1-score. O F1-score macro foi adotado como métrica principal por ser mais sensível ao desempenho nas classes minoritárias do que a acurácia global, que pode ser enganosa em datasets desbalanceados [Appasami and Savarimuthu 2024].

A análise qualitativa do aprendizado foi conduzida por meio de três recursos complementares: visualização dos mapas de ativação das camadas convolucionais, inspeção dos filtros aprendidos pela primeira camada e geração de mapas Grad-CAM (*Gradient-weighted Class Activation Mapping*) [Selvaraju et al. 2017] sobre imagens do conjunto de teste. O Grad-CAM calcula o gradiente da classe prevista em relação aos mapas de ativação da última camada convolucional, produzindo um mapa de calor que destaca as regiões da imagem que mais influenciaram a decisão do modelo.

4. Resultados

4.1. Desempenho quantitativo

A Tabela 2 apresenta as métricas obtidas pelos quatro modelos no conjunto de teste com 1.503 imagens. As métricas são calculadas com média macro sobre as sete classes do HAM10000.

Tabela 2. Resultados dos quatro modelos no conjunto de teste (média macro).

Modelo	Acurácia	Precisão	Recall	F1-score
CNN A - Tradicional	61,08%	51%	63,8%	52,6%
CNN B - Dilatada	67,07%	52,01%	65,9%	55,8%
CNN C - Depthwise	66,4%	51,1%	63,8%	54,2%
CNN D - Kernel 5×5	61,6%	47,01%	61,1%	50,1%

A CNN B, baseada em convolução dilatada, obteve o melhor desempenho em todas as métricas, com acurácia de 67,07% e F1-score macro de 55,82%. A CNN C, baseada em convolução depthwise separável, ficou em segundo lugar com F1-score de 54,29%, resultado expressivo considerando que sua primeira camada possui 82,7% menos parâmetros que a tradicional. A CNN D, com kernel 5×5, ficou abaixo da CNN A tradicional em F1-score, evidenciando que ampliar o campo receptivo pelo tamanho do kernel não garante melhor desempenho e impõe custo paramétrico 171% maior que a variante baseline.

A acurácia geral ficou entre 61% e 67% nos quatro modelos, reflexo do balanceamento de classes aplicado pelo *WeightedRandomSampler*. Em comparação com um experimento preliminar sem balanceamento, o F1-score macro subiu em média 14 pontos percentuais e o recall subiu 27 pontos, demonstrando que o tratamento do desbalanceamento é uma decisão de projeto tão relevante quanto a escolha da variante convolucional [Appasami and Savarimuthu 2024, Khan et al. 2026].

4.2. Convergência durante o treinamento

A análise das curvas de perda e acurácia de validação ao longo das 50 épocas, suavizadas com média móvel de 5 épocas, revela que a CNN B dilatada apresenta a menor perda de validação e a maior acurácia a partir da época 30, o que é coerente com o resultado da execução única sobre o conjunto de teste. A CNN A tradicional apresentou maior oscilação nas curvas de validação ao longo do treinamento, o que pode indicar menor estabilidade na generalização. O *scheduler* ReduceLROnPlateau reduziu o *learning rate* progressivamente ao longo das épocas, com valor final de $3,1 \times 10^{-5}$ ao término do treinamento.

4.3. Análise qualitativa do aprendizado

4.3.1. Mapas de ativação

A visualização dos mapas de ativação produzidos pelas camadas convolucionais revela diferenças no padrão de extração de características entre as variantes. As primeiras camadas da CNN A e da CNN B ativam bem a região central da lesão, com padrões relacionados a bordas e variações de cor. A CNN B dilatada apresenta ativações com maior cobertura espacial desde as camadas iniciais, consistente com seu campo receptivo efetivo de 7×7 pixels. A CNN C depthwise exhibe mapas mais distribuídos e com maior cobertura espacial nas duas camadas analisadas, mesmo com significativamente menos parâmetros convolucionais. A CNN D com kernel 5×5 apresenta ativações mais amplas que a tradicional nas primeiras camadas, refletindo o campo receptivo maior, mas sem superar a CNN B em cobertura da região da lesão.

4.3.2. Filtros aprendidos

A inspeção dos filtros da primeira camada convolucional revela estratégias de extração distintas entre as variantes. As CNNs A, B e D aprenderam filtros RGB coloridos com variação de matiz entre si, indicando especialização em combinações distintas de cor e textura, padrões típicos de características dermatoscópicas como pigmentação e estrutura vascular. A CNN C aprendeu filtros em escala de cinza, comportamento esperado e inerente à arquitetura depthwise separável, uma vez que a etapa *depthwise* opera canal por canal sem combinar os três canais RGB em uma única representação visual.

4.3.3. Grad-CAM

Os mapas Grad-CAM gerados sobre imagens de melanoma do conjunto de teste revelam diferenças na localização da atenção visual entre as quatro variantes. A CNN A tradicional concentra suas ativações em regiões periféricas da lesão e em cantos da imagem, o que é clinicamente menos adequado para a tarefa de classificação dermatoscópica. A CNN B dilatada apresenta ativações mais distribuídas pela região da lesão, consistente com seu campo receptivo efetivo mais amplo. A CNN C depthwise produziu o mapa Grad-CAM mais coerente clinicamente, com maior cobertura da região central da lesão melanocítica, sugerindo que a separação depthwise favorece atenção espacial mais concentrada na lesão. A CNN D com kernel 5×5 apresenta ativações mais amplas que a tradicional, mas menos concentradas na lesão central que a CNN C.

Esses resultados qualitativos corroboram os resultados quantitativos e sugerem que o tipo de convolução influencia não apenas o desempenho numérico, mas também a estratégia de atenção visual do modelo sobre as imagens dermatoscópicas.

4.4. Validação cruzada entre as variantes dilatada e depthwise

Para verificar a robustez da comparação entre as duas variantes de melhor desempenho, foi conduzida uma validação cruzada estratificada de 5 folds envolvendo a CNN B (dilatada) e a CNN C (depthwise separável). Em cada fold, os dois modelos foram treinados sob as mesmas condições e avaliados sobre o mesmo conjunto de teste, o que permite uma comparação pareada fold a fold. A Tabela 3 apresenta a média e o desvio padrão de cada métrica ao longo dos 5 folds. Os valores médios entre os folds são inferiores aos da execução única porque cada fold usa uma partição diferente de treino e validação.

Tabela 3. Média e desvio padrão das métricas ao longo dos 5 folds estratificados (comparação pareada, mesmo conjunto de teste).

Variante	Acurácia	Precisão	Recall	F1-score
CNN B - Dilatada	61,9% $\pm$ 2,6%	48,5% $\pm$ 2,4%	61,6% $\pm$ 3,1%	50,7% $\pm$ 3,0%
CNN C - Depthwise	63,5% $\pm$ 1,7%	49,1% $\pm$ 3,2%	65,2% $\pm$ 2,0%	52,5% $\pm$ 2,7%

As diferenças entre as médias das duas variantes são pequenas e ficam dentro da própria variação que cada modelo apresenta de um fold para o outro. A CNN C depthwise obteve média um pouco superior em quatro dos cinco folds, mas por uma margem parecida com a que cada variante já oscila sozinha entre os folds. Com apenas 5 folds, essa diferença é insignificante e insuficiente para apontar uma variante vencedora.

A leitura mais adequada é que a convolução dilatada e a depthwise separável apresentem desempenho equivalente dentro da margem de incerteza dos dados. Diante dessa equivalência, a redução de 82,7% no número de parâmetros da primeira camada torna a depthwise separável a opção mais vantajosa entre as duas para cenários com restrição de custo computacional.

5. Conclusão

Este trabalho investigou como quatro implementações distintas da camada convolucional 2D influenciam o processo de aprendizado de Redes Neurais Convolucionais aplicadas à classificação de imagens dermatoscópicas do dataset HAM10000. A abordagem comparativa controlada, com arquitetura idêntica entre os quatro experimentos e variação exclusiva do tipo de camada convolucional, permitiu atribuir diretamente ao tipo de convolução as diferenças observadas nos resultados quantitativos e qualitativos.

A convolução dilatada (CNN B) obteve o melhor desempenho em execução única em todas as métricas, com acurácia de 67,07% e F1-score macro de 55,82%, demonstrando que a ampliação do campo receptivo efetivo de 3×3 para 7×7 pixels, sem adição de parâmetros, favorece a captura de padrões de textura distribuídos nas lesões dermatoscópicas.

A convolução depthwise separável (CNN C) atingiu F1-score de 54,29% com 82,7% menos parâmetros convolucionais na primeira camada que a tradicional, evidenciando que a separação da operação convolucional em etapas depthwise e pointwise mantém

capacidade representacional competitiva com custo paramétrico significativamente reduzido.

A validação cruzada estratificada de 5 folds, conduzida entre a CNN B dilatada e a CNN C depthwise separável, mostrou diferenças de média e desvio padrão pequenas e insuficientes para separar as duas variantes em qualquer das quatro métricas. Esse resultado indica que, embora a CNN B tenha apresentado o melhor desempenho na avaliação de execução única sobre o conjunto de teste, as duas variantes têm desempenho equivalente dentro da margem de incerteza dos dados. Diante dessa equivalência, a redução de 82,7% no número de parâmetros da primeira camada torna a convolução depthwise separável a escolha mais vantajosa entre as duas para cenários com restrição de custo computacional.

A convolução com kernel 5×5 (CNN D) ficou abaixo da tradicional em F1-score, indicando que ampliar o campo receptivo pelo tamanho do kernel impõe custo paramétrico 171% maior sem garantir ganho de desempenho equivalente ao obtido pelo recurso de espaçamento da variante dilatada.

A análise qualitativa por meio de mapas de ativação, visualização de filtros e Grad-CAM revelou que o tipo de convolução influencia não apenas o desempenho numérico, mas também a estratégia de extração de características e a localização da atenção visual do modelo.

A análise qualitativa mostrou ainda que a CNN C depthwise, apesar de ficar atrás da CNN B no desempenho quantitativo de execução única, produziu os mapas Grad-CAM clinicamente mais coerentes, com maior cobertura da região central da lesão melanocítica. Esse resultado sugere que métricas quantitativas e análise qualitativa são complementares na avaliação de modelos para diagnóstico dermatoscópico assistido.

O tratamento do desbalanceamento de classes por meio do *WeightedRandomSampler* produziu ganho médio de 14 pontos percentuais no F1-score macro e de 27 pontos no recall em relação ao experimento sem balanceamento, confirmando que essa decisão de projeto é tão relevante quanto a escolha da variante convolucional [Appasami and Savarimuthu 2024, Khan et al. 2026].

Como trabalhos futuros, propõe-se a investigação das mesmas variantes convolucionais em arquiteturas mais profundas com conexões residuais, que permitem treinar redes com 8 ou mais camadas de forma estável e tendem a ampliar as diferenças de desempenho entre as variantes. A incorporação de transferência de aprendizado a partir de pesos pré-treinados em ImageNet e a aplicação de estratégias de aumento de dados mais agressivas, como *MixUp* e *CutOut*, também constituem direções promissoras para elevar as métricas de classificação nas classes minoritárias clinicamente relevantes, como melanoma e carcinoma basocelular.

Referências

- Almeida et al. (2025). Multi-class skin cancer detection using CNN-architecture based deep learning models. *Procedia Computer Science*.
- Appasami, G. and Savarimuthu, N. (2024). Enhanced skin cancer diagnosis using optimized CNN architecture and checkpoints for automated dermatological lesion classification. *BMC Medical Imaging*, 24.

- Chen et al. (2025). An advanced skin lesion segmentation and classification framework using deep learning strategies. *Scientific Reports*, 15:33926.
- Chollet, F. (2017). Xception: Deep learning with depthwise separable convolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 1251–1258.
- Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., and Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542:115–118.
- Khan, M. A. et al. (2026). An EfficientNetB4-based CNN model for skin lesion classification. *Engineering, Technology & Applied Science Research*.
- Lan et al. (2023). MSLAU-Net: a hybrid CNN-Transformer network for medical image segmentation. *arXiv preprint*.
- Li, Y., Hu, B., Wang, X., et al. (2025). Lightweight U-Net with depthwise separable convolution for skin lesion segmentation. *Scientific Reports*, 15:343.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., and Batra, D. (2017). Grad-cam: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 618–626.
- Tschandl, P., Rosendahl, C., and Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5:180161.