

P R O J E T O F I N A L

Reconhecimento de Emoções Faciais em Tempo Real

NAS via Optuna e YOLOv8, uma abordagem com validação cruzada
e restrições de GPU em nuvem

Wesley, Yure, Osevaldo, Guilherme e Arnaud

Sistemas de Visão Computacional, UFMA, PPGCC, 2026.1

Professor Dr. Geraldo Braz Júnior

São Luís (MA), 13 de julho de 2026

Roteiro da apresentação

01 Contexto e objetivo do sistema

02 Dataset FERPlus e pré-processamento

03 NAS com Optuna e validação cruzada

04 Treino final com regularização

05 Detecção de rostos com YOLOv8

06 Desafios com restrições de GPU no Kaggle

07 Resultados do NAS, do treino e da detecção

08 Conclusão e trabalhos futuros

Objetivo do sistema

Construir um sistema completo de FER em tempo real, da busca de arquitetura à integração com a câmera

O reconhecimento automático de emoções faciais (FER) identifica, em imagens ou vídeos de rostos, estados afetivos como raiva, nojo, medo, felicidade, tristeza, surpresa, desdenho e neutralidade, com aplicações em interfaces humano computador, saúde mental, educação e vigilância.

Três abordagens combinadas

1. NAS com o framework Optuna e validação cruzada de 3 folds sobre o conjunto de treino do FERPlus.
2. Estratégias de regularização para controle do overfitting no treino final da CNN, treinada do zero.
3. YOLOv8 submetido a fine-tuning para detecção de rostos em tempo real via webcam.

8

classes de emoções no FERPlus

48 x 48

pixels em escala de cinza

3 folds

de validação cruzada no NAS

66,78%

de acurácia de validação

Dataset FERPlus e pré-processamento

Extensão do FER2013 com rótulos de 10 avaliadores por imagem e a classe adicional desdenho

66.379

imagens de treino

8.341

imagens de validação

3.573

imagens de teste

8

pastas, uma por classe

Augmentation aplicada apenas ao conjunto de treino

1. Conversão para escala de cinza, imagens de 48 x 48 pixels.
2. Espelhamento horizontal aleatório com probabilidade 0,5.
3. Rotação aleatória de até 10 graus.
4. Translação aleatória de até 5% em cada eixo.
5. Normalização com média 0,5 e desvio padrão 0,5.

Validação e teste receberam apenas redimensionamento e normalização, sem augmentation, preservando a distribuição original para a avaliação.

Busca de arquitetura com NAS e Optuna

Amostragem bayesiana TPE, cada tentativa avaliada em 3 folds com 3 épocas por fold

Espaço de busca sugerido por tentativa

Camadas convolucionais	1 a 4
Filtros por camada	16 a 128, passo 16
Tamanho do kernel	3 ou 5
Neurônios na camada densa	64 a 256, passo 64
Taxa de dropout	0,2 a 0,5
Taxa de aprendizado	0,0001 a 0,01, escala logarítmica

Validação cruzada de 3 folds

Iteração 1, treina nos folds 2 e 3 e avalia no fold 1.
Iteração 2, treina nos folds 1 e 3 e avalia no fold 2.
Iteração 3, treina nos folds 1 e 2 e avalia no fold 3.

A métrica devolvida ao Optuna é a média das acurácias dos 3 folds.

Cerca de 13 minutos por tentativa na GPU Tesla T4 do Kaggle no primeiro ciclo, com 30 tentativas em 6 horas e 49 minutos.

Treino final com regularização

Estratégias adotadas progressivamente ao longo das iterações de melhoria

Dropout2d 0,2

Após cada camada convolucional, além do dropout padrão na camada densa.

AdamW com weight decay 0,0001

No lugar do Adam original, para regularização L2 nativa.

Label smoothing 0,1

Na função de perda CrossEntropyLoss, reduzindo a confiança excessiva do modelo.

ReduceLROnPlateau

Fator 0,5 e paciência de 3 épocas quando a acurácia de validação estagnava.

Early stopping

Paciência de 12 épocas sem melhoria de acurácia de validação.

Pesos por classe

Peso 2,0 para raiva, nojo, medo e tristeza, emoções menos detectadas na webcam.

Com autorização do orientador, a equipe realizou ajustes manuais sobre as arquiteturas de saída do NAS. O treino foi monitorado via Weights and Biases, com métricas por época e salvamento do modelo como artefato na nuvem.

Detecção de rostos com YOLOv8

Fine-tuning do YOLOv8 nano (yolov8n.pt) com dois datasets públicos combinados

O fine-tuning apenas com o WIDERFace, dataset com predominância de rostos pequenos em imagens de multidões, produzia baixa confiança em rostos frontais e próximos à câmera, padrão típico de uso com webcam.

O Face-Detection-Dataset complementou com rostos centralizados e em close, resultando em melhoria significativa da estabilidade do bounding box durante os testes.

O modelo resultante foi salvo como artefato no Weights and Biases, garantindo rastreabilidade e reprodutibilidade.

16.108

imagens de rostos no
WIDERFace

24.842

imagens de treino no
conjunto combinado

4.624


imagens de validação

30 épocas

imagens 640 x 640 e batch
size 16

Pipeline de execução por frame

Integração local em Python (reconhecimento_emocoes_webcam.py) combinando os dois modelos



Suavização temporal

Em caso de falha de detecção em um frame, o último retângulo detectado é mantido por até 8 frames antes de ser descartado, reduzindo a oscilação do retângulo delimitador.

Código-fonte completo disponível em github.com/osfarias/projetos, pasta reconhecimento-facial, fase-2.

Desafios com restrições de GPU no Kaggle

Cota de aproximadamente 30 horas semanais por conta e limite de 12 horas por sessão

01

Perda de sessão durante o NAS

O banco SQLite do Optuna ficava em kaggle working, diretório apagado ao encerrar a sessão, o que causou a perda de uma execução configurada para 70 tentativas. A solução foi salvar o arquivo .db como dataset no painel de inputs e copiá-lo ao iniciar novas sessões, retomando o estudo do ponto em que parou.

02

Persistência e auditoria dos estudos

Três bancos foram preservados, com 30, 102 e 107 tentativas, o que permitiu auditar os resultados com recuperação exata do melhor trial, da melhor acurácia média e dos hiperparâmetros de cada execução, aproveitando o histórico do amostrador TPE.

03

Uso de duas contas Kaggle

Para maximizar o tempo de GPU disponível, o projeto foi dividido entre duas contas, permitindo execuções em paralelo do NAS e do treino final em notebooks distintos.

Resumo das execuções do NAS com Optuna

Valores extraídos diretamente dos bancos de dados SQLite, garantindo rastreabilidade

Execução	Tentativas	Duração	Melhor acc. média	Melhor trial
1	30	6h49min	81,41%	15
2	102	aprox. 24h	81,00%	99
3 (continuação da 2)	107	não registrada	81,15%	106

A execução 3 estendeu o estudo da execução 2 e foi encerrada pelo esgotamento da cota semanal de GPU. O trial 15 propôs filtros 80, 112, 128 e 96 com densa de 256 neurônios. Os trials 99 e 106 convergiram para filtros iniciais menores e densa de 192 neurônios.

Convergência do espaço de busca

As três execuções convergiram para 4 camadas convolucionais, filtros em progressão crescente, camada densa enxuta e taxas de aprendizado na ordem de 0,001.

Diferenças inferiores a 0,5 ponto percentual entre os melhores trials sugerem um platô de desempenho para esse espaço de busca.

Comparativo das versões do treino final


Arquiteturas derivadas do NAS, de forma direta ou por ajuste manual autorizado

Versão	Épocas	Regularização	Pesos por classe	Arquitetura	Acc. val.
v1	30	Básica	Não	ajuste manual	66,11%
v2	50	Básica	Não	trial 15 da execução 1	65,27%
v3	40	AdamW, Dropout2d, smoothing	Não	não preservada	66,63%
v4 (melhor)	40	AdamW, Dropout2d, smoothing	Sim	ajuste manual	66,78%
v5	40 (early stop 31)	Completa	Não	não preservada	66,63%
v6	80 (early stop 44)	Completa	Sim	não preservada	65,66%


A v4 utilizou filtros 96, 96, 112 e 128, kernels 5, 3, 3 e 3, camada densa com 192 neurônios, dropout de 0,4 e weight decay de 0,0001, com diferença entre acurácia de treino (83%) e validação oscilando para menor em relação às demais versões. Os checkpoints das versões v3, v5 e v6 foram sobrescritos por execuções subsequentes em razão das restrições de sessão da plataforma.

Curvas de treino do modelo v6

Único histórico completo preservado, o histórico época a época do v4 foi sobrescrito



Curvas de loss de treino e validação do modelo v6



Curvas de acurácia de treino e validação do modelo v6

Leitura das curvas

Apesar da regularização completa, a v6 acionou o early stop após 15 épocas sem melhoras, com a diferença entre treino e validação estabilizada em 16 pontos percentuais.

As estratégias de regularização são eficazes na redução do overfitting, mas exigem microajustes, paciência e tempo de GPU.

O que o NAS previu e o que o treino confirmou

A média dos folds com 3 épocas indicou tendências, não a ordenação final entre arquiteturas

81,41%

média nos folds

Trial 15 da execução 1, melhor pontuação do NAS com apenas 3 épocas por fold.

65,27%

no treino completo

A mesma arquitetura do trial 15 treinada com o dataset completo, versão v2.

66,78%


com ajuste manual

Ajuste informado pelas tendências do NAS, regularização mais forte e pesos por classe, versão v4.


A acurácia média dos folds funcionou como indicador das tendências gerais do espaço de busca, como a profundidade de 4 camadas, os filtros crescentes e a camada densa enxuta, mas não como previsor da ordenação final entre arquiteturas no treino completo.

Detecção de emoções em tempo real


Sistema integrado testado com webcam, com detecção de múltiplos rostos simultâneos



Múltiplos rostos com classificação individual e simultânea



Dois rostos com emoções distintas, sem interferência



Detecção da emoção nojo

Sete das 8 emoções foram detectadas com sucesso nos testes. A limitação mais relevante foi a detecção instável quando o rosto ocupa grande parte do frame, atribuída ao WIDERFace. Após a combinação com o Face-Detection-Dataset, a estabilidade do bounding box melhorou significativamente.

O que o projeto mostrou

01

NAS viável sob restrição de GPU

Melhor arquitetura com acurácia média de 81,0% nos folds, com três execuções convergindo para os mesmos padrões.

02

Regularização reduziu o overfitting

A diferença entre treino e validação, que ultrapassava 30 pontos percentuais, foi contida, com melhor acurácia de validação de 66,78%.

03

Combinação de datasets melhorou a webcam

O acréscimo do Face-Detection-Dataset estabilizou o bounding box para rostos frontais e próximos à câmera.

04

Gerenciamento de estado foi decisivo

O salvamento contínuo do SQLite do Optuna e os artefatos no Weights and Biases eliminaram o risco de perda por sessão.

Trabalhos futuros

Direções identificadas para a continuidade do projeto

01

Mapas de calor para explicabilidade

Explicabilidade da detecção de rostos e da classificação de emoções, com ativação via tecla de atalho durante a demonstração em tempo real.

02

Ampliação do NAS para 200 tentativas

Estrutura com 150 tentativas com validação cruzada seguidas de 50 tentativas com o dataset completo sem divisão de folds.

03

Mecanismos de atenção

Arquiteturas com atenção sobre as regiões faciais mais relevantes para cada emoção, como olhos e boca.

04

Avaliação em condições controladas

Caracterização quantitativa do desempenho em ambiente real, com controle de iluminação e distância.

Referências bibliográficas

- AKIBA, T. et al. Optuna, a next-generation hyperparameter optimization framework. ACM SIGKDD, 2019.
- BARSOUM, E. et al. Training deep networks for facial expression recognition with crowd-sourced label distribution. ACM ICMI, 2016.
- FANG, B. et al. Expression-guided deep joint learning for facial expression recognition. Sensors, 2023.
- HUA, W. et al. A novel facial expression recognition approach combining Canny edge detection and convolutional neural networks. IET Software, 2025.
- TERVEN, J., CORDOVA-ESPARZA, D. A comprehensive review of YOLO architectures in computer vision. Machine Learning and Knowledge Extraction, 2023.
- WANG, X., ZHU, W. Advances in neural architecture search. National Science Review, 2024.
- WHITE, C. et al. Neural architecture search, insights from 1000 papers. arXiv, 2023.
- WU, M., TSAI, C. Training-free neural architecture search, a review. ICT Express, 2024.
- YANG, S. et al. WIDER FACE, a face detection benchmark. IEEE CVPR, 2016.
- YISIHAK, H. M., LI, L. Advanced face detection with YOLOv8. Scientific Research Publishing, 2024.
- ZHAO, F. et al. Introducing a novel dataset for facial emotion recognition. Heliyon, 2024.
- ZHAO, Z. et al. A perception CNN for facial expression recognition. arXiv, 2025.

Github do projeto final: <https://github.com/osfarias/projetos/tree/main/reconhecimento-facial/fase-2>

P R O J E T O F I N A L

Reconhecimento de Emoções Faciais em Tempo Real

Obrigado!

Wesley, Yure, Osevaldo, Guilherme e Arnaud

Sistemas de Visão Computacional, UFMA, PPGCC, 2026.1